

Análisis de Sentimiento en Reseñas Turísticas

Reseñas de hoteles en español · Informe de resultados
 Jorge Branly Carrizales Yampara

1. Objetivo

Implementar una solución de PLN de principio a fin sobre reseñas de hoteles en español que estime el sentimiento del huésped, lo desglose por aspecto (comida, servicio, limpieza y precio), compare un enfoque clásico con uno neuronal y lo exponga en una interfaz usable por cualquier persona.

2. Datos y preparación

Se utilizó el corpus público beltrewilton/punta-cana-spanish-reviews (34.561 reseñas, calificaciones de 1 a 5), cargado directamente desde Hugging Face para asegurar reproducibilidad. Las calificaciones se agruparon en tres clases: negativo (1-2), neutro (3) y positivo (4-5). Al estar el corpus fuertemente sesgado hacia lo positivo, se balanceó por submuestreo a 1.695 reseñas por clase (5.085 en total; 1.017 de prueba).




Figura 1. Distribución original del corpus, dominada por reseñas positivas. Motiva el balanceo previo al entrenamiento.

3. Metodología

Se mantuvieron dos pipelines de preprocesamiento: uno exhaustivo (limpieza, lematización con spaCy y filtrado de stopwords, conservando las negaciones) para TF-IDF y LDA; y uno ligero para BETO, que aprovecha el contexto completo. El modelo clásico combina TF-IDF (unigramas y bigramas) con Naive Bayes; el neuronal es BETO afinado a tres clases. El sentimiento por aspecto se estima localizando las frases que mencionan cada aspecto y evaluándolas con un modelo de sentimiento en español.

4. Resultados

Modelo	Accuracy	Precision	Recall	F1
Naive Bayes (TF-IDF)	0.734	0.735	0.734	0.734
BETO (Transformer)	0.807	0.809	0.807	0.808




Figura 2. Ambos modelos superan ampliamente el azar (0,33). BETO aventaja al clásico en ~7 puntos en todas las métricas.




Figura 3. La clase neutral es la más difícil para ambos; BETO la mejora 10 puntos (0,62 → 0,72).




Figura 4. Matriz de confusión del modelo Naive Bayes. La confusión se concentra en la clase neutral.

5. Interpretación

Los dos modelos aprenden señal real, pero el neuronal capta mejor el contexto: BETO alcanza 80,7 % de exactitud frente al 73,4 % del clásico. La clase neutral es la más difícil en ambos, algo esperable porque las opiniones neutras

mezclan elogios y quejas y su vocabulario es menos marcado; es justo ahí donde BETO aporta la mayor mejora. La clase positivo es la más fácil por su léxico claramente cargado.

6. Resultados



The image displays two screenshots of a web application titled "Analizador de Reseñas de Hoteles". The application interface includes a navigation bar with tabs for "Reseña individual", "Análisis por lote (CSV)", and "Métricas del modelo". The main content area shows a review text, a star rating, and sentiment analysis results for various aspects of the hotel experience.

Top Screenshot:

- Reseña:** La comida del restaurante dejaba mucho que desear por ser insípida, y el precio cobrado resulta excesivo para lo que ofrecen. Aunque la limpieza era aceptable, el servicio del personal fue frío, lento y con muy poca disposición para ayudar al huésped.
- Estrellas estimadas:** 2.0 / 5
- Sentimiento general:** Negativo
- Sentimiento por aspecto:**
 - Comida: Neutral
 - Servicio: Negativo
 - Limpieza: Neutral
 - Precio: Negativo

Bottom Screenshot:

- Reseña:** El mal servicio arruinó nuestra estadia, ya que ignoraron por completo nuestras quejas sobre la evidente falta de limpieza en los baños. Además, la calidad de la comida es muy baja y definitivamente no compensa el elevado precio que cobran por alojarse.
- Estrellas estimadas:** 1.5 / 5
- Sentimiento general:** Negativo
- Sentimiento por aspecto:**
 - Comida: Negativo
 - Servicio: Negativo
 - Limpieza: Negativo
 - Precio: Negativo



7. Conclusion

El proyecto cumple los requisitos del módulo: pipeline reutilizable, modelado de temas (LDA), análisis de sentimiento general y por aspecto, comparación clásico vs. neuronal con métricas e interfaz funcional. La conclusión es clara y alineada con la teoría: el enfoque moderno (BETO) rinde mejor, pero el clásico sigue siendo un baseline valioso por su rapidez y bajo costo. El sistema resuelve bien la tarea con un modelo de tamaño moderado, priorizando eficiencia sobre complejidad.

7. Limitaciones y mejoras

- **Jergas y expresiones personalizadas:** no reconoce modismos regionales ni expresiones muy coloquiales ('de lujo', 'una estafa', 'ni de chiste'); mejoraría con un diccionario de jerga turística o afinando BETO con reseñas locales.
- **Ironía y sarcasmo:** frases como 'excelente, si te gusta pasar frío' se malinterpretan; requieren datos etiquetados con ironía.
- **Aspectos por palabras clave:** depende de una lista fija de términos y no separa bien aspectos dentro de una misma frase; un modelo de Aspect-Based Sentiment Analysis entrenado sería superior.
- **Pérdida de datos por balanceo:** el submuestreo descarta muchas reseñas positivas; podría probarse oversampling o ponderación de clases.
- **Emojis y ortografía:** la limpieza elimina emojis (que cargan sentimiento) y no corrige errores ortográficos, frecuentes en reseñas reales.
- **Temas del LDA:** incluyen verbos genéricos poco informativos; alimentar el modelo con bigramas y ampliar las stopwords mejoraría su interpretabilidad.